

Tecnológico de Monterrey

Plataforma Agéntica **Plan preliminar de proyecto**

Equipo “Fortech”

A01198786, Diego Hernández Herrera

A01255389, Lucio E. Collins Ramírez

A00838627, Bruno Fernando Zabala Peña

A01255389, Humberto Cañedo Cebreros

A01255019, Monserrath Valenzuela Sánchez

[[ER-PA-001]]

[v1]

[02/03/2026]

Contenido

1. Introducción.....	3
1.1 Definición del Proyecto.....	3
1.2 Problemática o Necesidad que se Busca Resolver.....	3
1.3 Contexto del Proyecto.....	3
1.4 Usuarios Objetivo.....	4
1.5 Funcionalidades Principales del Sistema.....	4
1.6 Objetivo General del Proyecto.....	5
1.7 Justificación del Desarrollo.....	5
2. Plan.....	5
2.1 Definición del alcance del proyecto.....	5
2.2 Restricciones identificadas.....	5
2.3 Supuestos del proyecto.....	5
2.4 Consideraciones iniciales sobre viabilidad.....	5
3. Roadmap.....	5
4. WBS.....	6

1. Introducción

El presente documento constituye el Plan Preliminar de Proyecto, una plataforma web de automatización multi-agéntica desarrollada por el equipo Fortech, en colaboración con Banorte. El documento establece el marco de referencia inicial del proyecto, describiendo la problemática identificada, el contexto organizacional, los usuarios objetivo, las funcionalidades principales del sistema y la justificación técnica y de negocio que fundamenta su desarrollo.

1.1 Definición del Proyecto

La Plataforma Agéntica será una plataforma web de tipo low-code/no-code orientada a la creación, configuración, orquestación y ejecución de agentes de Inteligencia Artificial. La plataforma permitirá que usuarios no técnicos diseñen agentes inteligentes desde una interfaz visual declarativa, asignándoles modelos de lenguaje (LLM), herramientas externas, bases de conocimiento y comportamientos específicos mediante configuración, sin necesidad de escribir código.

El sistema estará construido sobre una arquitectura de tres capas: un frontend web declarativo desarrollado en Next.js, un motor de ejecución multi-agente basado en el Agent Development Kit (ADK) de Google en Python, y una capa de persistencia y autenticación sobre Supabase. Los agentes podrán ser orquestados en workflows complejos con flujos secuenciales, paralelos o jerárquicos, y su ejecución contará con indicadores de estado visibles al usuario (procesando, ejecutando herramienta, generando respuesta).

1.2 Problemática o Necesidad que se Busca Resolver

Banorte busca optimizar sus procesos de back-office, donde actualmente hay un volumen alto de tareas repetitivas que requieren entender lo que dicen los clientes, consultar información interna y tomar decisiones. Los agentes de IA ofrecen una solución más flexible y adaptable para manejar estas tareas de forma más eficiente.

Adicionalmente, las soluciones existentes de agentes de IA en el mercado presentan barreras de adopción significativas: requieren conocimientos avanzados de programación, no ofrecen visibilidad sobre el razonamiento del agente, y carecen de controles de seguridad adecuados para entornos financieros regulados. Esto genera una brecha entre las capacidades que ofrece la IA generativa moderna y la posibilidad real de implementarla de manera controlada y auditable dentro de la institución.

En concreto, las necesidades identificadas son:

- Crear y configurar agentes de IA sin desarrollo complejo ni conocimientos de programación avanzados.
- Orquestar múltiples agentes de manera coordinada bajo un modelo estructurado (ADK-MCP).
- Garantizar trazabilidad completa del razonamiento y las decisiones de cada agente.
- Controlar el acceso y el aislamiento entre usuarios, agentes y datos mediante políticas de seguridad robustas.
- Disponer de una interfaz conversacional que permita interactuar con los agentes y verificar sus respuestas de forma inmediata.

1.3 Contexto del Proyecto

La plataforma se desarrolla en el contexto de Banorte, una institución bancaria mexicana de primer nivel cuyas operaciones internas involucran grandes volúmenes de consulta documental, atención a clientes internos y procesamiento de información sobre productos financieros. La organización requiere una solución tecnológica que permita desplegar capacidades de IA de manera escalable y segura, sin depender de equipos de desarrollo para cada nuevo caso de uso.

El proyecto surge como iniciativa del equipo Fortech, como parte de un ejercicio académico aplicado a un caso de uso real dentro del sector financiero. El primer caso de uso concreto será un chatbot interno de consulta de productos de tarjetas, donde ejecutivos del área comercial podrán cargar documentación oficial y hacer preguntas en lenguaje natural sobre beneficios, tasas y condiciones de los productos.

Desde el punto de vista arquitectónico, la plataforma operará como una capa de orquestación que se conectará con modelos fundacionales de lenguaje de terceros como Gemini y Claude, APIs externas, bases de datos relacionales y vectoriales a través de Supabase, y herramientas externas mediante el protocolo MCP. El

sistema estará pensado para escalar hacia casos de uso más complejos como análisis documental, automatización de back-office y validaciones regulatorias.

1.4 Usuarios Objetivo

La plataforma estará orientada a dos perfiles de usuario en su fase inicial:

- **Usuario Interno (Área Comercial)**
Colaboradores del área de ventas o ejecutivos comerciales de Banorte que promueven y colocan productos de tarjetas. Requieren acceso rápido a información sobre características, beneficios, comisiones, tasas y condiciones de los productos. Interactúan con la plataforma principalmente a través de la interfaz de chat, cargando documentación oficial y realizando consultas en lenguaje natural. No requieren conocimientos técnicos ni de programación.
- **Usuario Cliente**
Clientes potenciales o actuales de Banorte que buscan información clara sobre productos de tarjetas. En esta fase inicial, su interacción está limitada a un entorno interno controlado. Realizan preguntas en lenguaje natural y reciben respuestas fundamentadas exclusivamente en los documentos oficiales cargados por los usuarios internos. No requieren conocimientos técnicos.

1.5 Funcionalidades Principales del Sistema

La plataforma contempla las siguientes funcionalidades principales, derivadas del proceso de levantamiento y refinamiento de requerimientos realizado con el equipo Fortech:

- Crear agentes desde una interfaz web declarativa, especificando nombre (único por *workflow*), descripción, objetivos y límites operativos como campos, obligatorios.
- Configurar un *system prompt* dinámico que defina la personalidad, comportamiento y restricciones del agente. La instrucción del sistema (system) se concatena al inicio de cada interacción con el LLM.
- La plataforma permitirá seleccionar el modelo LLM a utilizar (Gemini, Claude, Model Garden, entre otros) y ajustar los parámetros que controlan el estilo de sus respuestas. Estos parámetros son: temperatura, que determina qué tan creativas o predecibles serán las respuestas del agente; límite vocabulario (top-k), que define el número máximo de palabras que el modelo puede considerar al generar cada respuesta; y cobertura de probabilidad (top-p), que establece qué tan seguro debe estar el modelo de sus opciones antes de elegir una palabra. El sistema mostrará valores recomendados por defecto según el modelo seleccionado.
- Asignar subagentes como herramientas mediante relación muchos a muchos, y configurar servidores MCP indicando URL, nombre, esquema de autenticación, formato de datos y herramientas expuestas, con validación de conectividad obligatoria previa al guardado.
- Definir funciones personalizadas (*Function Calling*) mediante nombre, descripción, parámetros de entrada (nombre y tipo) y endpoint de ejecución, con capacidad de activar o desactivar cada función individualmente.
- Conectar el agente a una base de datos vectorial (RAG) que acepta archivos en formato PDF, TXT, DOCX, Markdown e imágenes, consultada automáticamente antes de cada respuesta del agente.
- Forzar el formato de salida del agente en JSON, Markdown o esquema personalizado, con reintento automático ante incumplimiento del esquema y bloqueo de la respuesta si el reintento falla.

- Editar la configuración completa de agentes existentes. La edición queda bloqueada si el agente tiene conversaciones activas en curso.
- Eliminar agentes con validación previa de referencias activas en otros agentes. Listar agentes con paginación, búsqueda por nombre y filtro por herramientas asignadas.

1.6 Objetivo General del Proyecto

Desarrollar una plataforma web de automatización multiagéntica que permita a usuarios no técnicos de Banorte crear, configurar, orquestar y ejecutar agentes de Inteligencia Artificial desde una interfaz visual declarativa, con el fin de automatizar tareas repetitivas de consulta y procesamiento de información, reducir tiempos operativos y habilitar la adopción controlada y trazable de IA generativa dentro de los procesos internos de la organización.

1.7 Justificación del Desarrollo

Los modelos de lenguaje de gran escala han alcanzado un nivel de madurez suficiente para ser desplegados en entornos productivos con alta fiabilidad. Sin embargo, su adopción en instituciones financieras requiere infraestructura especializada que garantice trazabilidad, control de acceso y separación de contextos. La plataforma proveerá esta infraestructura de manera estandarizada, con el objetivo de reducir el tiempo de despliegue de nuevos casos de uso de semanas a horas mediante su arquitectura declarativa.

Banorte gestiona internamente un alto volumen de consultas sobre productos financieros que actualmente dependen de la disponibilidad y conocimiento individual de ejecutivos comerciales. La implementación de un chatbot interno basado en documentación oficial reduce la variabilidad de las respuestas, garantiza que la información proporcionada esté fundamentada en fuentes verificadas y libera tiempo operativo de los equipos de ventas.

La plataforma será diseñada como infraestructura base reutilizable para múltiples casos de uso futuros dentro de Banorte y en otros sectores. Su arquitectura modular, desacoplada y orientada a eventos permitirá incorporar nuevos agentes, herramientas e integraciones sin modificar el núcleo del sistema. Esto busca convertir al proyecto en una inversión de plataforma con alto potencial de retorno a largo plazo, más allá del caso de uso inicial.

La plataforma representa una propuesta, una respuesta técnicamente fundamentada a la necesidad de Banorte de incorporar capacidades de Inteligencia Artificial en sus operaciones de manera controlada, escalable y accesible para usuarios no técnicos, con el propósito de sentar las bases para una adopción institucional progresiva de la automatización agéntica.

2. Plan

2.1 Definición del alcance del proyecto

El proyecto se desarrolla a lo largo de seis sprints que abarcan desde el 2 de marzo hasta el 22 de mayo de 2026, con cuatro fechas de entrega acordadas con Banorte.

Sprint 0: Setup y arranque (2 mar - 13 mar)

El objetivo de este sprint es terminar la documentación pendiente y dejar preparado el entorno técnico para que el equipo pueda iniciar con el desarrollo con la arquitectura y las herramientas correctamente definidas.

Sprint 1: Auth y Dashboard (16 mar – 27 mar)

Se establece el sistema de autenticación y el dashboard personal del usuario.

Sprint 2: Agente Base y Chat (30 mar – 10 abr)

Se desarrolla el primer agente funcional y la interfaz de chat, lo que permite validar de extremo a extremo la autenticación, los permisos, la base de datos y la integración con el LLM, funcionan correctamente juntos.

Sprint 3: Canvas, RAG y Triggers (13 abr – 24 abr)

Incorpora las capacidades avanzadas de la plataforma: el canvas visual de workflows, el nodo RAG, las herramientas de function calling y los triggers automáticos.

Sprint 4: Orquestador Multiagente (27 abr – 8 may)

Desarrolla la orquestación multiagente con logging y métricas de ejecución.

Sprint 5: QA y Cierre (11 may – 22 may)

Se dedica a pruebas, correcciones y la documentación de entrega al cliente.

2.2 Restricciones identificadas

El frontend deberá desarrollarse en [Next.js](#). La base de datos, autenticación y almacenamiento estarán gestionados exclusivamente por Supabase. El motor de ejecución de agentes estará construido sobre el Agent Development Kit de Google en Python, operando como un servicio independiente. La integración de herramientas externas con los agentes deberá realizarse bajo el protocolo MCP. Toda la infraestructura correrá en contenedores Docker, con tres contenedores definidos: frontend, motor de agentes y Supabase.

El proyecto tiene fechas de entrega fijas acordadas con el cliente:

- 2 de marzo: Entrega parcial.
- 11 de marzo: Primera presentación
- 29 de abril: Segunda presentación
- 10 de junio: Presentación final

2.3 Supuestos del proyecto

- Disponibilidad de modelos de lenguaje: se asume que los proveedores de modelos (Anthropic, Google, etc.) mantendrán la disponibilidad de estos a lo largo del desarrollo del proyecto (tanto APIs como el modelo para su contenerización).
- Calidad de la información proporcionada a las bases de datos para RAG: se asume que todos los documentos que el equipo interno de Banorte proporciona a los nodos para RAG son oficiales, contienen información verídica, actualizada y relevante para el flujo sobre el que se está trabajando.
- Estabilidad de los servicios de nube y backend: se asume que los servicios proporcionados por Google Cloud, Supabase y cualquier otra plataforma que pueda llegar a ser utilizada durante el desarrollo del proyecto se mantendrán disponibles y que los recursos que se nos proporcionen o estén a nuestro alcance (por ejemplo, la *tier* o los créditos gratuitos de alguno de estos servicios) serán suficientes para trabajar sin complicaciones durante todos los sprints.
- Conectividad de red: se asume que el usuario final, ya sea alguien interno de Banorte o alguno de sus clientes, cuenta con una conexión estable a internet, la cual le permita interactuar correctamente con la interfaz de usuario y tener una experiencia de uso fluida.
- Curva de aprendizaje del sistema: aunque uno de los objetivos del proyecto es llegar a un sistema cuya usabilidad sea lo más intuitiva posible, se asume que todos los usuarios que vayan a tener acceso a la plataforma tendrán al menos una capacitación básica sobre el uso de herramientas para la automatización de flujos de trabajo.

2.4 Consideraciones iniciales sobre viabilidad

Las tecnologías seleccionadas son maduras (son sólidas, fiables) y están bien documentadas, y el ADK de Google ofrece soporte nativo para los patrones de orquestación que se necesitan implementar.

Los sprints iniciales están diseñados para que el equipo pueda familiarizarse con las nuevas tecnologías antes de abordar los componentes más complejos. En términos de tiempo. Cada sprint tiene un objetivo claro y

Los riesgos más relevantes a monitorear del proyecto, son la disponibilidad de las API 's de los modelos de lenguaje en el proceso de pruebas de la Orquestación, los posibles cambios de requerimientos tras las presentaciones con Banorte, y la disponibilidad del cliente para dar retroalimentación en cada entrega.

3. Roadmap

4. WBS

