

Plataforma Agéntica Web Low-Code / No-Code con Orquestación Multi-Agente (ADK-MCP)

1. Introducción

La presente Reto tiene como objetivo que el equipo diseñe, implemente y entregue una plataforma agéntica web enterprise-grade, que permita la creación, orquestación y operación de agentes de Inteligencia Artificial, bajo un enfoque low-code / no-code, cumpliendo con requerimientos estrictos de seguridad, cumplimiento regulatorio, trazabilidad, explicabilidad y resiliencia.

2. Objetivo del Reto

Entrega de solución que permita la creación de agentes de IA con bajo o nulo código, soporte orquestaciones multi-agente bajo un modelo ADK-MCP y cumpla con principios de Zero Trust, observabilidad, control de costos y cumplimiento regulatorio.

3. Alcance

El team deberá entregar una plataforma web completa, documentación técnica y operativa, evidencias de seguridad y cumplimiento, así como arquitectura de referencia y lineamientos operativos.

4. Requerimientos Funcionales

4.1 Creación de Agentes

La plataforma deberá permitir la creación de agentes mediante interfaz web declarativa, definiendo modelos LLM (fundacionales o de terceros), configuraciones de LLM, objetivos, límites, fuentes de datos, herramientas permitidas, niveles de autonomía y versionamiento.

1. Inyección de System Prompt Dinámico

Es la configuración más crítica. Debe permitir que el usuario defina la **personalidad y reglas** del agente.

- **A nivel técnico:** El LLM debe recibir un `system_instruction` o `system_message` que se concatena al inicio de cada interacción.
- **Ejemplo de customización:** "Eres un experto en soporte técnico amable" vs. "Eres un analista de datos sarcástico".

2. Control de Parámetros de Generación

No todos los agentes deben ser creativos. Se debe permitir al usuario ajustar la "**temperatura**" del modelo:

- **Temperature:** Entre 0.0 (determinista/preciso para finanzas o código) y 1.0 (creativo para marketing).
- **Top-P / Top-K:** Para limitar la diversidad del vocabulario y evitar que el agente divague.

3. Selección de Herramientas (Tool Definition)

Para que el agente sea funcional, el usuario debe elegir qué puede "hacer":

- **Configuración:** Habilitar un selector de Function Calling donde el usuario activa o desactiva permisos (ej: "Consultar inventario", "Enviar correos", "Buscar en Google").

4. Gestión de Memoria y Contexto

Permite al usuario decidir qué tanto debe "recordar" el agente:

- **Ventana de Contexto (Window Size):** Cuántos mensajes previos se envían al LLM.
- **Memoria Persistente:** Opción de conectar el agente a una base de datos vectorial (RAG) con documentos específicos del usuario (PDFs, manuales, etc).

5. Configuración de Seguridad y Guardrails

Indispensable para evitar que el agente se salga de control:

- **Safety Settings:** Filtros de severidad para contenido de odio, acoso o sugerencias peligrosas.

6. Estructura de Respuesta (Output Formatting)

- **Formato:** Forzar al agente a responder siempre en **JSON**, **Markdown** o un esquema específico para que la interfaz del usuario siempre sepa cómo mostrar la información.

4.2 Orquestación Multi-Agente (ADK-MCP)

La solución deberá soportar flujos secuenciales, paralelos y jerárquicos entre múltiples agentes, con delegación explícita y control de contexto compartido.

4.3 Seguridad (Security by Design)

Se deberá implementar arquitectura Zero Trust, autenticación multifactor obligatoria, aislamiento fuerte entre agentes, datos y usuarios, así como cifrado en tránsito y en reposo.

4.4 Observabilidad y Trazabilidad

La plataforma deberá capturar el razonamiento completo del agente, incluyendo decisiones, contexto, herramientas utilizadas y permitir su visualización end-to-end.

4.5 Cumplimiento Regulatorio

La solución deberá demostrar cumplimiento con LIC, PLD/FT y gobierno de modelos, incluyendo registros inmutables y capacidad de auditoría completa.

5. Entregables Esperados

Plataforma funcional, documentación técnica y de auditoría, arquitectura de referencia y manuales de operación.

6. Requerimientos no funcionales

A. Seguridad (Security by Design, no como feature)

✓ Aceptación

- Zero Trust Architecture explícita.
- Cero vulnerabilidades Críticas y Altas (SAST, DAST, DSC, Container, Secrets)
- Autenticación multifactor obligatoria (no opcional).
- Aislamiento fuerte entre:
 - agentes
 - datos
 - prompts
- Protección contra:
 - prompt injection
 - data leakage entre usuarios
 - jailbreaks de agentes
- Cifrado:
 - En tránsito (TLS 1.3)
 - En reposo (AES-256 o equivalente)
- Observabilidad
 - **Trazabilidad del Razonamiento (Chain of Thought)**

- **Criterio:** El sistema debe capturar y persistir el **flujo de pensamiento** completo del agente (pasos internos, herramientas consultadas y lógica de decisión).
- **Validación:** Se debe poder visualizar en un dashboard el "trace" completo de una consulta, desde el *prompt* inicial hasta la respuesta final, incluyendo las llamadas intermedias a APIs.
- **Monitoreo de Uso de Herramientas (Tool Use & Execution)**
 - **Criterio:** Registro obligatorio de cada llamada a funciones externas
 - **Validación:** Cada llamada a una herramienta debe registrar: nombre de la función, argumentos de entrada, tiempo de respuesta y si el resultado fue exitoso o fallido (manejo de errores de integración).
- **Métricas de Fidelidad y Alucinación (Evals)**
 - **Criterio:** Implementación de un sistema de **evaluación automática** (con un "agente juez" o LLM-as-a-judge) para medir la veracidad de las respuestas.
 - **Validación:** Generar un reporte semanal de métricas de **Groundedness** (sustento en la fuente) y **Relevance** (relevancia de la respuesta) sobre una muestra del 10% de las interacciones.
- **Control de Costos y Latencia por Paso**
 - **Criterio:** Medición del consumo de tokens (input/output) y tiempo de ejecución desglosado por cada etapa de la cadena.
 - **Validación:** El sistema debe alertar si un agente entra en un **bucle infinito** de llamadas o si una sola sesión supera un umbral de costo (ej. \$1 USD por conversación) o latencia (ej. > 15 segundos).
- **Captura de Feedback del Usuario (Human-in-the-loop)**
 - **Criterio:** Correlación directa entre la traza técnica del agente y la calificación del usuario final (likes/dislikes/comentarios).
 - **Validación:** Los logs deben incluir un ID de sesión único que vincule el feedback del usuario con los logs de ejecución del agente para realizar análisis de causa raíz.

✗ Rechazo inmediato si

- El agente "recuerda" datos de otros usuarios.
- No se puede explicar qué datos vio el agente y por qué actuó.
- La seguridad depende de "buen comportamiento del usuario".

B. Cumplimiento Regulatorio (Compliance-first, no afterthought)

✅ Aceptación

Evidencia explícita de cumplimiento con:

- Ley de Instituciones de Crédito (LIC)
- PLD / FT
- Gobierno de modelos (explicabilidad, trazabilidad)

Registro inmutable de:

- Decisiones
- Recomendaciones
- Fuentes de datos

Capacidad de:

- Congelar al agente
- Reproducir una decisión histórica exacta (auditoría).

❌ Rechazo inmediato si

- “El modelo decide” sin explicación.
- No existe bitácora auditable.
- El sistema no puede operar en modo “safe / degraded”.

C. Arquitectura Escalable y Resiliente

✅ Aceptación

- Arquitectura desacoplada (event-driven).
- Autoescalabilidad en picos de demanda.
- Manejo de fallas parciales sin caída total (Circuit Breaker)
- Latencia máxima en respuestas 3 seg
- Pruebas de caos o escenarios de falla documentados.

❌ Rechazo inmediato si

- Es un monolito frágil.
- Un solo agente crítico puede tirar la plataforma.
- No existe estrategia de recuperación.

D. Estandarización

✅ Aceptación

Uso de estándares:

- APIs versionadas
- contratos claros
- modelos de datos canónicos
- Agentes reemplazables (plug & play).

Documentación clara para:

- Operación
- Auditoría
- Continuidad

✗ Rechazo inmediato si

- La solución depende de “la persona que la programó”.
- No puede ser operada por un equipo distinto al creador.
- Es irreplicable o no portable.

E. Simplicidad Operativa

✓ Aceptación

- El usuario entiende:
 - Qué hace el agente
 - Qué no hace
 - Cómo detenerlo
- Flujos simples, deterministas en procesos críticos.
- IA asiste, no sustituye controles clave.

✗ Rechazo inmediato si

- El sistema es una “caja negra”.
- El usuario confía sin entender.
- La IA toma decisiones irreversibles sin validación.